# SEIRD Data Fitting Model from Henri Froesi for Brazilian States Covid19 - Evolution and Prediction

## References:

### [1] Modelling Beyond the Basic SIR Model - Henri Froesi - Towards Data Science

https://towardsdatascience.com/infectious-disease-modelling-beyond-the-basic-sir-model-216369c584c4 (https://towardsdatascience.com/infectious-disease-modelling-beyond-the-basic-sir-model-216369c584c4)

### [2] Infectious Disease Modelling. Fitting Your Model to Corona Virus Data - Henri Froesi-Towards Data Science

https://towardsdatascience.com/infectious-disease-modelling-fit-your-model-to-coronavirus-data-2568e672dbc7 (https://towardsdatascience.com/infectious-disease-modelling-fit-your-model-to-coronavirus-data-2568e672dbc7)

### Adapted by Ivan Carlos P. da Cruz (GitHub @icpcruz)

### Revision and contributions by Eduardo Correa Araújo

# Model summary ref. [1]

# Imports

In [1]:

```
import numpy as np
import pandas as pd
pd.options.mode.chained_assignment = None  # default='warn'

import matplotlib.pyplot as plt
import matplotlib.dates as mdates
%matplotlib inline

from scipy.integrate import odeint

# !pip install lmfit - DONE !
import lmfit
from lmfit import Model # classe lmfit para a criação do modelo de fitting

import numdifftools # permite que lmfit calcule a matriz de correlações

import datetime

import warnings
warnings.filterwarnings('ignore')
```

**para centralizar os gráficos na página**

In [2]:

```
from IPython.core.display import HTML
HTML("""
<style>
.output_png {
    display: table-cell;
    text-align: center;
    vertical-align: middle;
}
</style>
""")
```

Out[2]:

# Importação de dados de óbitos diários por estado brasileiro (NE)

## Diretório sincronizado com o GitHub dos dados (arquivos csv):

In [3]:

```
path = "C:/Users/Ivan/Documents/GitHub/googleData/data/"
```

## Dicionário de nomes dos arquivos de óbitos diários por estado do NE

In [4]:

```
pref = "ON"
suf  = "_An.csv"
Data_files_names = {
    "Alagoas"    : pref+"AiL"+suf ,
    "Bahia"      : pref+"BiA"+suf ,
    "Ceará"      : pref+"CiE"+suf ,
    "Maranhão"   : pref+"MiA"+suf ,
    "Paraíba"    : pref+"PiB"+suf ,
    "Pernambuco" : pref+"PiE"+suf ,
    "Piauí"      : pref+"PiI"+suf ,
    "RioGrdoN"   : pref+"RiN"+suf ,
    "Sergipe"    : pref+"SiE"+suf
}
```

## Leitura dos arquivos (atualizados diariamente)

In [5]:

```
data_ON_AL = pd.read_csv(path+Data_files_names["Alagoas"], sep =",")
data_ON_BA = pd.read_csv(path+Data_files_names["Bahia"], sep =",")
data_ON_CE = pd.read_csv(path+Data_files_names["Ceará"], sep =",")
data_ON_MA = pd.read_csv(path+Data_files_names["Maranhão"], sep =",")
data_ON_PB = pd.read_csv(path+Data_files_names["Paraíba"], sep =",")
data_ON_PE = pd.read_csv(path+Data_files_names["Pernambuco"], sep =",")
data_ON_PI = pd.read_csv(path+Data_files_names["Piauí"], sep =",")
data_ON_RN = pd.read_csv(path+Data_files_names["RioGrdoN"], sep =",")
data_ON_SE = pd.read_csv(path+Data_files_names["Sergipe"], sep =",")
```

## "Parsing" das datas

In [6]:

```
format_str = "%Y-%m-%d"
data_ON_AL['Data'] = data_ON_AL['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
data_ON_BA['Data'] = data_ON_BA['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
data_ON_CE['Data'] = data_ON_CE['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
data_ON_MA['Data'] = data_ON_MA['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
data_ON_PB['Data'] = data_ON_PB['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
data_ON_PE['Data'] = data_ON_PE['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
data_ON_PI['Data'] = data_ON_PI['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
data_ON_RN['Data'] = data_ON_RN['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
data_ON_SE['Data'] = data_ON_SE['Data'].apply(lambda x:datetime.datetime.strptime(x,for
mat_str))
```

In [7]:

```
data_ON_CE.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 85 entries, 0 to 84
Data columns (total 2 columns):
Data        85 non-null datetime64[ns]
ONCiE_An    85 non-null float64
dtypes: datetime64[ns](1), float64(1)
memory usage: 1.4 KB
```

In [8]:

```
data_ON_CE.tail()
```

Out[8]:

| | Data | ONCiE_An |
|---|---|---|
| **80** | 2020-06-05 | 77.0 |
| **81** | 2020-06-06 | 75.0 |
| **82** | 2020-06-07 | 17.0 |
| **83** | 2020-06-08 | 138.0 |
| **84** | 2020-06-09 | 189.0 |

In [9]:

```
data_ON_CE.describe()
```

Out[9]:

| | ONCiE_An |
|---|---|
| **count** | 85.000000 |
| **mean** | 50.694118 |
| **std** | 60.005560 |
| **min** | 0.000000 |
| **25%** | 4.000000 |
| **50%** | 25.000000 |
| **75%** | 75.000000 |
| **max** | 261.000000 |

## Definindo as colunas 'Data' como índices

In [10]:

```
data_ON_AL.set_index('Data')
data_ON_BA.set_index('Data')
data_ON_CE.set_index('Data')
data_ON_MA.set_index('Data')
data_ON_PB.set_index('Data')
data_ON_PE.set_index('Data')
data_ON_PI.set_index('Data')
data_ON_RN.set_index('Data')
data_ON_SE.set_index('Data')
data_ON_CE.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 85 entries, 0 to 84
Data columns (total 2 columns):
Data        85 non-null datetime64[ns]
ONCiE_An    85 non-null float64
dtypes: datetime64[ns](1), float64(1)
memory usage: 1.4 KB
```

# Parâmetros Epidemiológicos Assumidos para a Covid-19 (como universais) p/o SEIRD

In [11]:

```
#
# VALORES MÉDIOS ASSUMIDOS (ref. https://theconversation.com/how-long-are-you-infectious-when-you-have-coronavirus-135295):
#
num_of_incubation     = 5      # número de dias de incubação da doença (1/delta).
num_of_infecting_days = 9      # número de dias que um infectado (ativo) infecta outros (= D = 1/gama)
num_to_dead           = 17     # número de dias para evoluir de infectado para óbito (1/rho)
subnotif_index        = 12     # número de vezes que os casos reais de infectados é maior que os notificados
apparent_letality     = 0.065  # taxa aparente de letalidade (% dos notificados que vão a óbito)
#
Epi_days              = 200    # duração arbitrada da pandemia
#
# FREQUÊNCIAS (POR DIA) CORRESPONDENTES
#
alpha = apparent_letality/subnotif_index
delta = 1/num_of_incubation
gamma = 1/num_of_infecting_days
rho   = 1/num_to_dead
#
print('\n','*** PARÂMETROS EPIDEMIOLÓGICOS ADOTADOS NO MODELO SEIRD:','\n')
print('    Freq de letalidade   (alpha) = {:.3f}'.format(alpha))
print('    Freq de incubação    (delta) = {:.3f}'.format(delta))
print('    Freq de infetividade (gamma) = {:.3f}'.format(gamma))
print('    Freq para óbito      (rho)   = {:.3f}'.format(rho))
```

```
 *** PARÂMETROS EPIDEMIOLÓGICOS ADOTADOS NO MODELO SEIRD:

    Freq de letalidade   (alpha) = 0.005
    Freq de incubação    (delta) = 0.200
    Freq de infetividade (gamma) = 0.111
    Freq para óbito      (rho)   = 0.059
```

## Dados da população por estado

In [12]:

```
N_BR ={"Brasil": 210147125,
             "Nordeste":
                 {'MA':7075181,
                  'PI':3273227,
                  'CE':9132078,
                  'RN':3506853,
                  'PB':4018127,
                  'PE':9557071,
                  'AL':3337357,
                  'SE':2298696,
                  'BA':14873064},
             "Norte":
                 {'RO':1777225,
                  'AC':881935,
                  'AM':4144597,
                  'RR': 605761,
                  'PA':8602865,
                  'AP':845731,
                  'TO':1572866},
             "Sudeste":
                 {'MG':21168791,
                  'ES':4018650,
                  'RJ':17264943,
                  'SP':45919049},
             "Sul":
                 {'PR':11433957,
                  'SC':7164788,
                  'RS':11377239},
             "Centro-Oeste":
                 {'MS':2778986,
                  'MT':3484466,
                  'GO':7018354,
                  'DF':3015268} }
```

# Modelo com R_0 (e "beta") dependentes do tempo

### Função sistema de EDOs do modelo SEIRD que é recursivamente chamada pelo solver das ODEs

In [13]:

```
def deriv(y, t, N, beta, gamma, delta, alpha, rho):
    #
    S, E, I, R, D = y
    #
    dSdt = -beta(t) * S * I / N
    dEdt = beta(t) * S * I / N - delta * E
    dIdt = delta * E - (1 - alpha) * gamma * I - alpha * rho * I
    dRdt = (1 - alpha) * gamma * I
    dDdt = alpha * rho * I
    #
    return dSdt, dEdt, dIdt, dRdt, dDdt
```

## R_0(t) como uma função degrau de 2 alturas (c/5 parâms a serem ajustados pelo algorítimo de fitting/otimização)

In [14]:

```
def dois_saltos_R_0(t, R_0_start, x0, R_0_mid, x1, R_0_end):
    if (R_0_start>R_0_mid>R_0_end) and (x0<x1):
        if t < x0:
            f = R_0_start
        elif x0 <=t < x1:
            f = R_0_mid
        else:
            f = R_0_end
    else:
        f = np.average(np.absolute(np.array([R_0_start, R_0_mid, R_0_end])))
    return f
```

## Gráfico da função degrau para R*0*(t) (OBS: não há interpolação linear entre os patamares)

In [15]:

```
xt=np.arange(10)
yt=np.zeros(10)
i = 0
for item in xt:
    yt[i] = dois_saltos_R_0(xt[i], 8, 4, 6, 8, 4)
    i += 1

plt.figure(figsize = [10, 4])
plt.xlim(0,10)
plt.plot(xt, yt, label = 'Função degrau de 2 passos e 5 params.', color='r')
plt.legend()
plt.show()
```

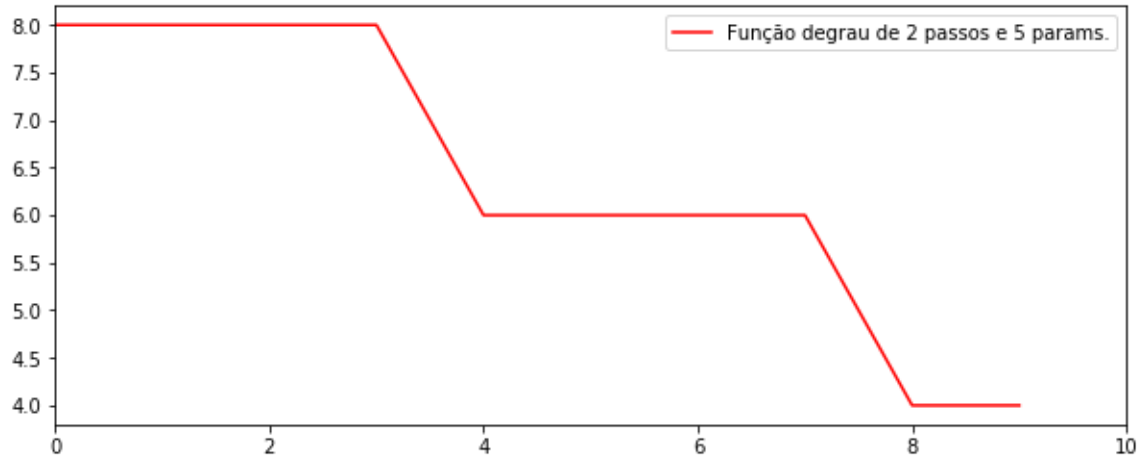


**Os parâmetros que serão ajustados no processo de otimização (fitting), são:**

**Valores inicias arbitrados dos parâmetros para o processo de otimização dados como tuplas (esperado, mínimo, máximo)**

In [16]:

```
params_init_min_max = {"R_0_start": (3.5, 2.0, 6.0),
                       "x0":        (10.0, 2.0, 100.0),
                       "R_0_mid":   (1.5, 0.5 , 3),
                       "x1":        (110, 100.1, 250),
                       "R_0_end":   (0.6, 0.1, 1.5)}
```

# Ajuste das curvas R_0(t) e SEIRD a partir dos dados de mortalidade diária

## Definição da função solver do sistema de EDOs do modelo SEIRD que é recursivamente chamada pelo algoritmo de otimização (fitting aos dados)

In [17]:

```
def SolverEDOs(days, N, R_0_start, x0, R_0_mid, x1, R_0_end):
    #
    # definição da função beta(t) = R_0(t)*gama
    #
    def beta(t):
        return dois_saltos_R_0(t, R_0_start, x0, R_0_mid, x1, R_0_end) * gamma
    #
    # Valores iniciais das variáveid do SEIRD: N-1 (população), 1 exposto, 0 infectado,
recuperados ou mortos
    #
    y0 = N-1.0, 1.0, 0.0, 0.0, 0.0
    #
    # geração da grid temporal a partir da quantidade de dias informados
    #
    t = np.arange(days)
    #print(t)
    #
    # Integração do sistema de EDOs - o sistema é passado pela função 'deriv' na chamad
a do solver
    #
    ret = odeint(deriv, y0, t, args=(N, beta, gamma, delta, alpha, rho))
    #
    # Salvando os resultados nas variáveis do sistema
    #
    S, E, I, R, D = ret.T
    #
    # Cálculo de R_0(t)
    #
    R_0_over_time = [beta(i)/gamma for i in range(len(t))]
    #
    return t, S, E, I, R, D, R_0_over_time
```

## Estado teste: Maranhão

In [18]:

```
N = N_BR['Nordeste']['MA']                  # <-- população do estado
y_data = data_ON_MA['ONMiA_An'].to_numpy() # <-- de pandas series para numpy array - nd
array
x_data = np.arange(len(y_data))             # <-- do dia 1 ao final da série (Python ini
cia em 'zero', daí o +1)
days   = len(x_data)                        # <-- duração, até "hoje", da pandemia no es
tado, para o fitting dos parâmetros
```

## Definição da função de fitting que chama o solver das EDOs

In [19]:

```
def fitter(x, R_0_start, x0, R_0_mid, x1, R_0_end):
    ret = SolverEDOs(days, N, R_0_start, x0, R_0_mid, x1, R_0_end) # <-- chama solver d
as EDOs (q chama odeint para integrar)
    deaths_fitted = ret[5]                                          # <-- óbitos: 6o
 elem. da tupla (t, S, E, I, R, D, R_0)
    return deaths_fitted[x]                                         # <-- retorna vet
or com as fatalidades no tempo
```

## Criando o modelo de fitting com o pacote 'lmfit'

In [20]:

```
# Cria o modelo de fitting passando a função fitter como parâmetro para lmfit
#
mod = lmfit.Model(fitter)
#
# Criação do vetor de parâmetros para o fitting, incluindo 3 estimativas iniciais (inic
ial, min, max) p/cada parâmetro
#
for kwarg, (init, mini, maxi) in params_init_min_max.items(): # <-- usa as estimativas
 fornecidas acima
    mod.set_param_hint(str(kwarg), value=init, min=mini, max=maxi, vary=True)
#
# Criação do vetor de parâmetros para o otimizador
#
params = mod.make_params()
```

In [21]:

```
params
```

Out[21]:

| name | value | initial value | min | max | vary |
|---|---|---|---|---|---|
| R_0_start | 3.50000000 | None | 2.00000000 | 6.00000000 | True |
| x0 | 10.0000000 | None | 2.00000000 | 100.000000 | True |
| R_0_mid | 1.50000000 | None | 0.50000000 | 3.00000000 | True |
| x1 | 110.000000 | None | 100.100000 | 250.000000 | True |
| R_0_end | 0.60000000 | None | 0.10000000 | 1.50000000 | True |

## Realizando o fitting com os dados de óbitos diários (não suavizados)

In [22]:

```
result = mod.fit(y_data, params, method="least_squares", x=x_data)
```

In [23]:

```
result.plot_fit(datafmt="-");
```

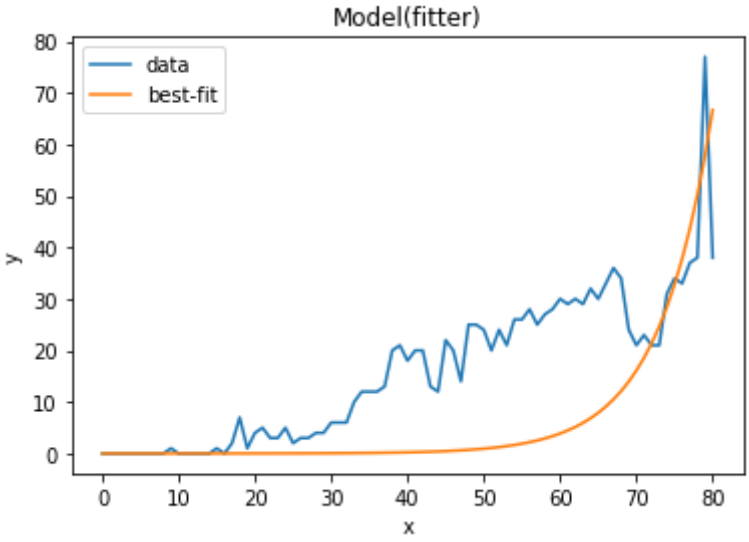

In [24]:

```
result
```

Out[24]:

# Model

Model(fitter)

# Fit Statistics

| | |
|---|---|
| fitting method | least_squares |
| # function evals | 6 |
| # data points | 81 |
| # variables | 5 |
| chi-square | 17546.3799 |
| reduced chi-square | 230.873420 |
| Akaike info crit. | 445.630456 |
| Bayesian info crit. | 457.602702 |

# Variables

| name | value | initial value | min | max | vary |
|---|---|---|---|---|---|
| R_0_start | 3.90426960 | 3.5 | 2.00000000 | 6.00000000 | True |
| x0 | 95.2067214 | 10.0 | 2.00000000 | 100.000000 | True |
| R_0_mid | 1.54105437 | 1.5 | 0.50000000 | 3.00000000 | True |
| x1 | 110.000000 | 110 | 100.100000 | 250.000000 | True |
| R_0_end | 0.60000000 | 0.6 | 0.10000000 | 1.50000000 | True |

# Realizando o fitting com os dados de óbitos diários suavizados (por média móvel)

In [25]:

```
window_size = 10 #  <-- tamanho da janela móvel para a suavização

# First, we need to convert y_data Numpy ndarray to a Pandas Series

y_series = pd.Series(y_data)

# Tail-rolling average transform

y_rolling_S = y_series.rolling(window=window_size).mean().dropna()

# Now getting back to a ndarray

y_rolling = y_rolling_S.to_numpy()
x_rolling = x_data[window_size-1:] # <-- remove os 'n-1' pontos do início da série por
 conta da média móvel sobre 'n' pontos
```

In [26]:

```
result_roll = mod.fit(y_rolling, params, method="least_squares", x=x_rolling)
```

In [27]:

```
result_roll.plot_fit(datafmt="-");
```

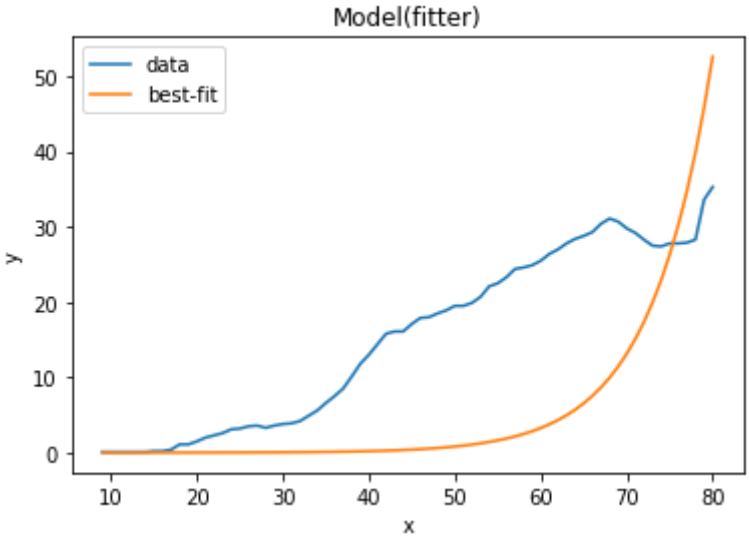

In [34]:

```
result_roll
```

Out[34]:

# Model
Model(fitter)

# Fit Statistics

| | |
|---|---|
| fitting method | least_squares |
| # function evals | 7 |
| # data points | 72 |
| # variables | 5 |
| chi-square | 13580.0523 |
| reduced chi-square | 202.687347 |
| Akaike info crit. | 387.257761 |
| Bayesian info crit. | 398.641092 |

# Variables

| name | value | initial value | min | max | vary |
|---|---|---|---|---|---|
| R_0_start | 3.81311450 | 3.5 | 2.00000000 | 6.00000000 | True |
| x0 | 95.2066904 | 10.0 | 2.00000000 | 100.000000 | True |
| R_0_mid | 1.53318643 | 1.5 | 0.50000000 | 3.00000000 | True |
| x1 | 110.000000 | 110 | 100.100000 | 250.000000 | True |
| R_0_end | 0.60000000 | 0.6 | 0.10000000 | 1.50000000 | True |

## Parâmetros otimizados do modelo com dados diários (suavizados)

### Vetor de parâmetros para usar na geração dos gráficos e data_frame dos forecasts

In [37]:

```
paramsfit = result_roll.best_values
#
parametros = []
parametros.append(paramsfit['R_0_start'])
parametros.append(paramsfit['x0'])
parametros.append(paramsfit['R_0_mid'])
parametros.append(paramsfit['x1'])
parametros.append(paramsfit['R_0_end'])
```

### Parâmetros da função R_0(t) (função degrau - 2 saltos)

In [38]:

```
print('\n','*** PARÂMETROS OTIMIZADOS DA FUNC 2-DEGRAUS DE R_0 PELO FITTING COM OS DADO
S DE ÓBITOS:','\n')
print('    R_0_start = {:.2f}'.format(paramsfit['R_0_start']))
print('    x_0       = {:.2f}'.format(paramsfit['x0']))
print('    R_0_mid   = {:.2f}'.format(paramsfit['R_0_mid']))
print('    x_1       = {:.2f}'.format(paramsfit['x1']))
print('    R_0_end   = {:.2f}'.format(paramsfit['R_0_end']))
```

```
 *** PARÂMETROS OTIMIZADOS DA FUNC 2-DEGRAUS DE R_0 PELO FITTING COM OS DA
DOS DE ÓBITOS:

    R_0_start = 3.81
    x_0       = 95.21
    R_0_mid   = 1.53
    x_1       = 110.00
    R_0_end   = 0.60
```

## Chamada do SOLVER com os parâmetros otimizados da função degrau para R_0(t) para obter as var SEIRD

In [35]:

```
#
# Definição do período da pandemia para efeito de traçar-se os gráficos de evolução r p
oder fazer forecast
#
Epi_days = 250 # <-- tempo estimado de duração da pandemia
```

In [39]:

```
res_SEIRD_roll = SolverEDOs(Epi_days, N,*parametros)
```

# Relatórios de acurácia e intervalo de confiança do fitting dos dados suavizados

In [43]:

```
plt.figure(figsize = [12, 4])
#plt.xlim(30,60)
plt.title('R_0')
plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[6], label = 'R_0')
```

Out[43]:

```
[<matplotlib.lines.Line2D at 0x1d8c181d1d0>]
```

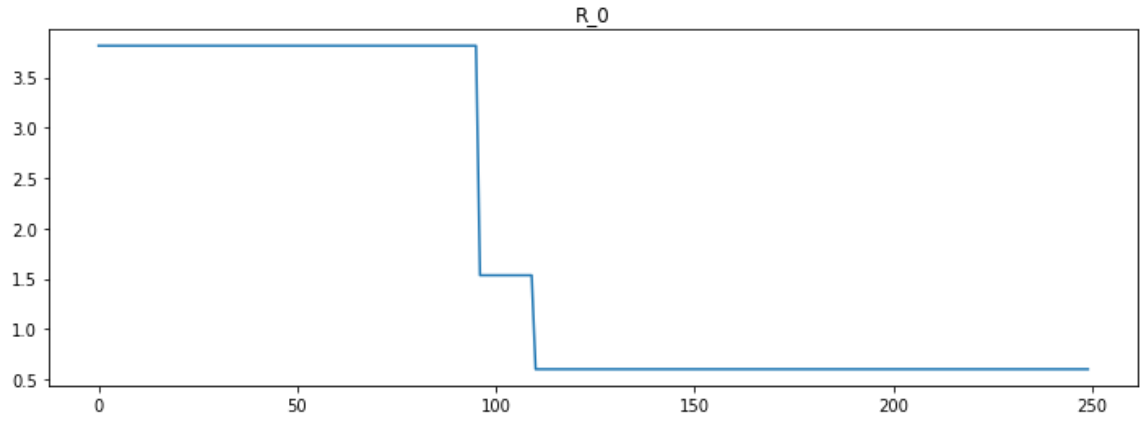


## Intervalos de confiança (processamento leva +6 mins.)

In [ ]:

```
#start_time = time.time()
#
#Conf_Interval = result_roll.ci_report()
#elapsed_time = time.time() - start_time
#elapsed_time
```

In [ ]:

```
#Conf_Interval
```

## Plotagem dos resíduos

In [44]:

```
result_roll.plot() # _residuals
```

Out[44]:

```
(<Figure size 432x432 with 2 Axes>, GridSpec(2, 1, height_ratios=[1, 4]))
```

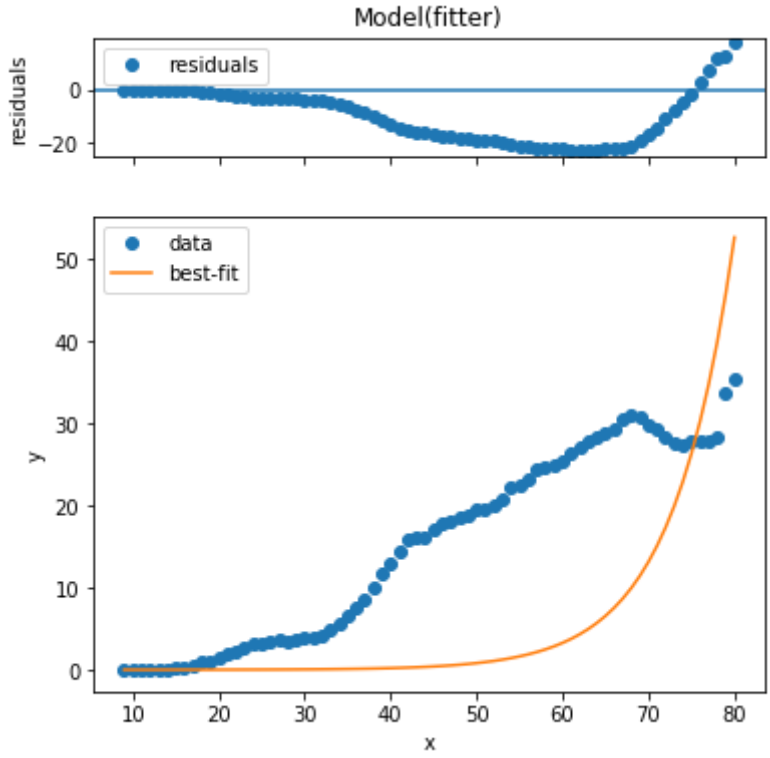


## Avaliação das incertezas - 50% e 90% de intervalos de confiança

In [45]:

```
result_roll_50 = result_roll.eval_uncertainty(x=x_rolling, sigma = 0.50)

result_roll_90 = result_roll.eval_uncertainty(x=x_rolling, sigma = 0.90)

plt.figure(figsize = [17, 6])
plt.xlim(30,80)
plt.title('Faixa de Incertezas para o Modelo Suavizado')
plt.plot(x_rolling, y_rolling, label='Curva dos dados suavizados')
plt.plot(x_rolling, result_roll.best_fit, label= 'Curva do melhor ajuste')
plt.fill_between(x_rolling, result_roll.best_fit-result_roll_90,
                 result_roll.best_fit+result_roll_90, color='#A8A8A8',label = 'Faixa de
confiança de 90%')
plt.fill_between(x_rolling, result_roll.best_fit-result_roll_50,
                 result_roll.best_fit+result_roll_50, color='#888888', label = 'Faixa d
e confiança de 50%')
plt.legend(loc=2)
plt.show()
```

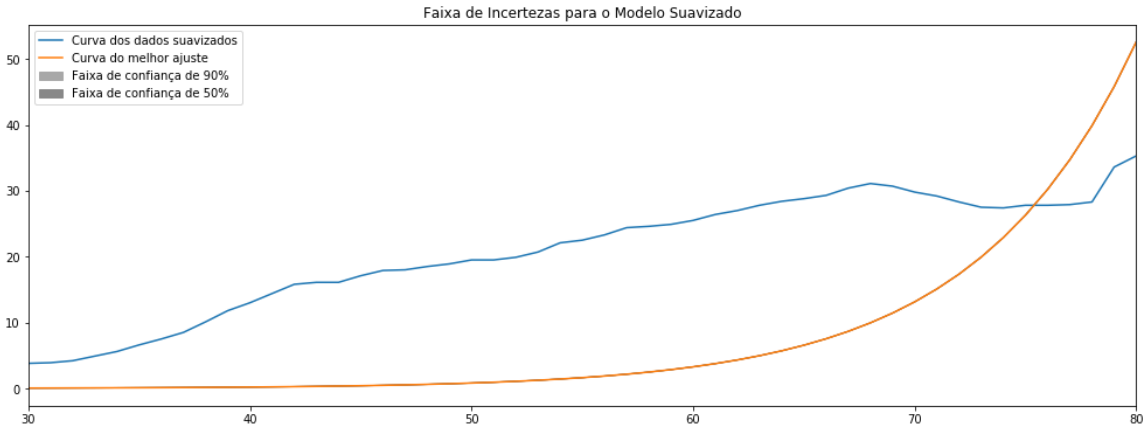


In [47]:

```
res_SEIRD_roll = SolverEDOs(Epi_days, N,*parametros)
```

# Plotagem das curvas SEIRD para o modelo com dados suavizados

## Curvas IED (S e R fora de escala nessa fase da pandemia)

In [49]:

```
plt.figure(figsize = [17, 6])
plt.title('Curvas SEIRD: [EID]')
plt.xlim(20,250)
#plt.plot(res_SEIRD[0],res_SEIRD[1], label = 'Suscetíveis')
plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[2], label = 'Infectados')
plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[3], label = 'Expostos')
#plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[4], label = 'Recuperados')
plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[5], label = 'Óbitos')
plt.legend()
plt.show()
```

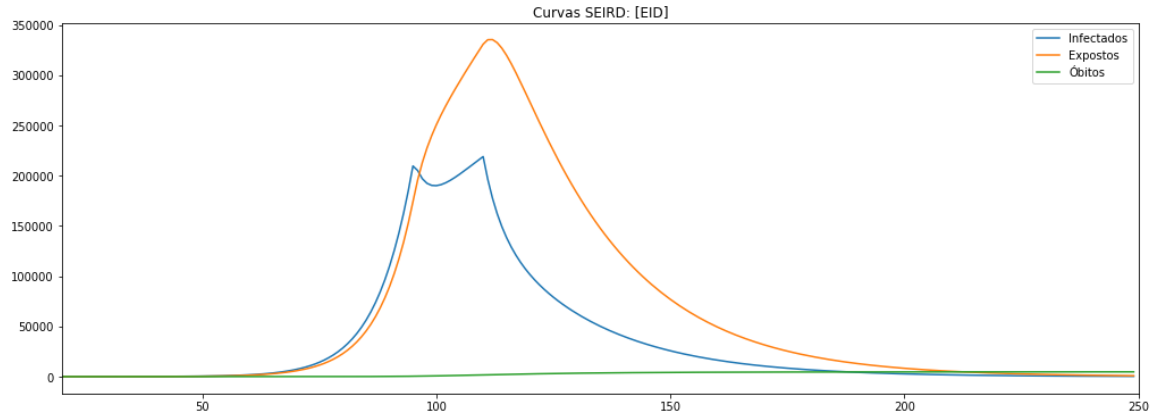


In [51]:

```
plt.figure(figsize = [17, 6])
plt.title('Curvas SEIRD: [IR]')
plt.xlim(20,250)
#plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[1], label = 'Suscetíveis')
plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[2], label = 'Infectados')
#plt.plot(dados[0],dados[3], label = 'Expostos')
plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[4], label = 'Recuperados')
plt.legend()
plt.show()
```

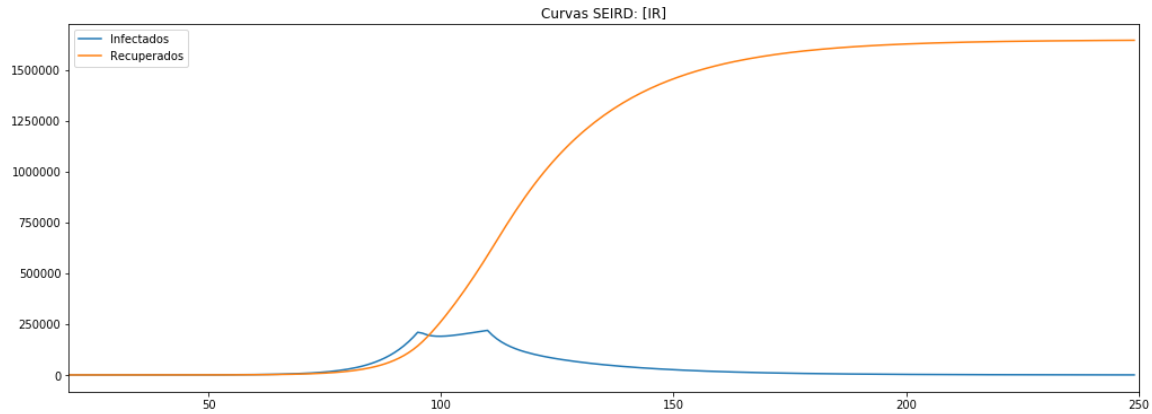


## Ajuste da curva estimada de óbitos aos dados suavizados (média móvel de 10 dias)

In [53]:

```
plt.figure(figsize = [17, 6])
plt.xlim(10,250)
#plt. ylim(0,40)
plt.bar(x_data, y_data,                          label = 'Dados de obitos')
plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[5], label = 'Óbitos estimados suavizados', co
lor='black')
plt.bar(x_rolling, y_rolling,                    label = 'Óbitos suavizados por Média-Móve
l', color='red')
plt.legend()
plt.show()
```

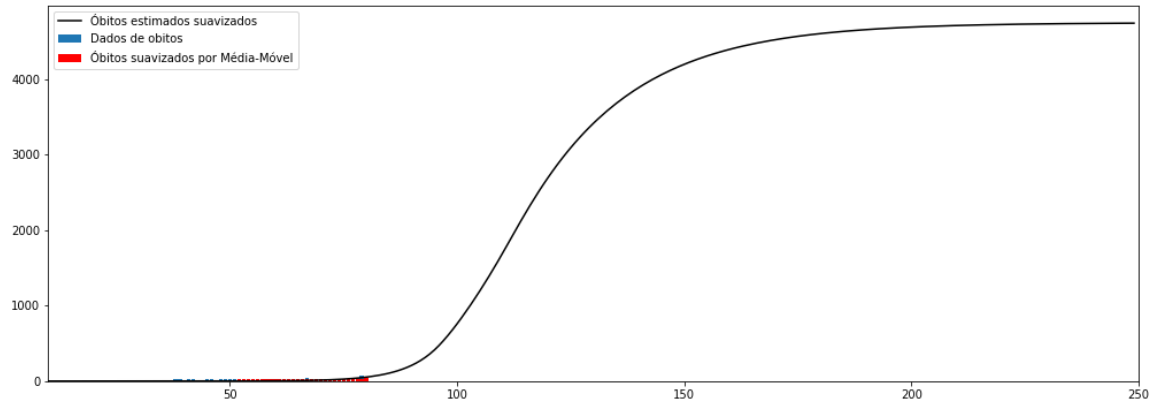


## Zoom no trecho com dados

In [60]:

```
plt.figure(figsize = [17, 6])
plt.xlim(10,90)
plt. ylim(0,80)
plt.bar(x_data, y_data,                          label = 'Dados de obitos')
plt.plot(res_SEIRD_roll[0],res_SEIRD_roll[5], label = 'Óbitos estimados suavizados', co
lor='black')
plt.bar(x_rolling, y_rolling,                    label = 'Óbitos suavizados por Média-Móve
l', color='red')
plt.legend()
plt.show()
```

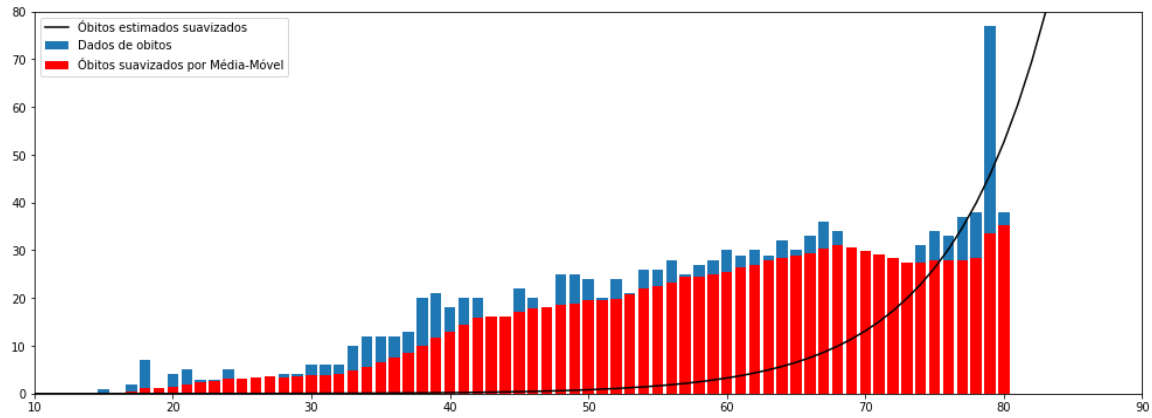


## Forecast para 14 dias (com os dados suavizados)

In [54]:

```
period = 14 #<-- days forecast
#
last_day_in_data = x_rolling[len(x_rolling) - 1]
last_day_forecast  = last_day_in_data + period
```

In [55]:

```
Day = pd.Series(res_SEIRD_roll[0])
S   = pd.Series(res_SEIRD_roll[1])
E   = pd.Series(res_SEIRD_roll[2])
I   = pd.Series(res_SEIRD_roll[3])
R   = pd.Series(res_SEIRD_roll[4])
D   = pd.Series(res_SEIRD_roll[5])
```

In [56]:

```
df = pd.DataFrame()
df['Dia da Epidemia'] = Day
df['Suscetíveis']     = S
df['Expostos']        = E
df['Infectados']      = I
df['Recuperados']     = R
df['Óbitos']          = D
#
df.set_index(['Dia da Epidemia'])
#
pd.options.display.float_format = '{:,.0f}'.format
df[last_day_in_data : last_day_forecast]
```

Out[56]:

| | Dia da Epidemia | Suscetíveis | Expostos | Infectados | Recuperados | Óbitos |
|---|---|---|---|---|---|---|
| **80** | 80 | 7,005,561 | 28,447 | 22,872 | 18,249 | 53 |
| **81** | 81 | 6,995,280 | 32,629 | 26,252 | 20,959 | 60 |
| **82** | 82 | 6,983,501 | 37,415 | 30,126 | 24,069 | 69 |
| **83** | 83 | 6,970,008 | 42,890 | 34,565 | 27,638 | 80 |
| **84** | 84 | 6,954,561 | 49,147 | 39,649 | 31,733 | 91 |
| **85** | 85 | 6,936,887 | 56,293 | 45,468 | 36,428 | 105 |
| **86** | 86 | 6,916,678 | 64,446 | 52,124 | 41,813 | 121 |
| **87** | 87 | 6,893,586 | 73,739 | 59,733 | 47,984 | 138 |
| **88** | 88 | 6,867,224 | 84,318 | 68,425 | 55,055 | 159 |
| **89** | 89 | 6,837,157 | 96,344 | 78,345 | 63,152 | 182 |
| **90** | 90 | 6,802,902 | 109,994 | 89,654 | 72,422 | 209 |
| **91** | 91 | 6,763,924 | 125,459 | 102,533 | 83,025 | 239 |
| **92** | 92 | 6,719,637 | 142,941 | 117,180 | 95,148 | 274 |
| **93** | 93 | 6,669,398 | 162,659 | 133,812 | 108,997 | 314 |

In [57]:

```
df.describe()
```

Out[57]:

| | Dia da Epidemia | Suscetíveis | Expostos | Infectados | Recuperados | Óbitos |
|---|---|---|---|---|---|---|
| **count** | 250 | 250 | 250 | 250 | 250 | 250 |
| **mean** | 124 | 6,136,225 | 33,018 | 59,534 | 843,971 | 2,433 |
| **std** | 72 | 738,215 | 57,919 | 94,600 | 733,140 | 2,114 |
| **min** | 0 | 5,424,507 | 1 | 0 | 0 | 0 |
| **25%** | 62 | 5,440,616 | 501 | 1,086 | 1,554 | 4 |
| **50%** | 124 | 5,702,170 | 4,103 | 8,881 | 1,059,252 | 3,054 |
| **75%** | 187 | 7,069,224 | 33,372 | 72,858 | 1,609,932 | 4,642 |
| **max** | 249 | 7,075,180 | 219,069 | 335,539 | 1,644,708 | 4,742 |